

Analiza danych z międzynarodowych badań edukacyjnych w R z użyciem pakietu Rrepest

Jakub Łobaszewski (j.lobaszewski@ibe.edu.pl)

Mateusz Kleczaj (m.kleczaj@ibe.edu.pl)

Spis treści

1	Wprowadzenie	3
1.1	Dlaczego warto używać Rrepest?	4
1.2	Ograniczenia Rrepest	5
1.3	Obsługiwane badania	5
2	Instalacja pakietów i przygotowanie danych do analizy	5
3	Składnia i kluczowe opcje funkcji Rrepest()	6
3.1	Struktura danych w międzynarodowych badaniach edukacyjnych	8
3.1.1	Nazwy zmiennych z wartościami prawdopodobnymi (PV)	8
3.1.2	Nazwy zmiennych wag analitycznych	8
4	Pobieranie danych	9
4.1	Struktura plików danych	10
4.1.1	Struktura danych IEA	10
4.1.2	Struktura danych OECD	11
5	Analiza danych PISA 2022	11
5.1	Przygotowanie danych	11
5.2	Przykład 1 – średnia i odchylenie standardowe wyników umiejętności czytania według kraju i płci	12
5.3	Przykład 2 – Tabela rozkładów częstości płci uczniów	12
5.4	Przykład 3 – Regresja liniowa: analiza wpływu statusu społeczno-ekonomicznego rodziny na osiągnięcia ucznia w dziedzinie matematyki:	13
5.5	Przykład 4 – Regresja logistyczna: wpływ statusu społeczno-ekonomicznego rodziny na osiągnięcia ucznia w dziedzinie matematyki (uzyskanie wyniku na poziomie co najmniej 626 punktów):	14

6	Analiza danych TIMSS 2023 (klasa 4)	16
6.1	Przygotowanie danych krok po kroku	16
6.1.1	Połączenie danych	16
6.1.2	Utworzenie 250 wag replikacyjnych zgodnie z zastosowaną w badaniu TIMSS metodą Jackknife Repeated Replication (JRR)	18
6.1.3	Zmiana wielkości liter w nazwach zmiennych	18
6.2	Przykład 1 – Średni wynik z matematyki według kraju i płci	19
6.3	Przykład 2 – Średni wynik z matematyki według kraju i płci, z zastosowaniem parametru over i pokazaniem różnicy wyników pomiędzy płciami (chłopcy – dziewczęta) w poszczególnych krajach	19
6.4	Przykład 3 – Tabela rozkładów częstości płci uczniów	19
6.5	Przykład 4 – Regresja liniowa: wpływ płci ucznia oraz braku wczesnych aktywności związanych z liczeniem na osiągnięcia uczniów w dziedzinie matematyki	20
6.6	Analizy na danych nauczycieli matematyki (TIMSS 2023)	21
6.6.1	Przygotowanie danych i budowa wag replikacyjnych dla nauczycieli zgodnie z zastosowaną w badaniu TIMSS 2023 metodą Jackknife Repeated Replication (JRR)	22
6.6.2	Przykład 5 – Odsetki nauczycieli matematyki według wieku	23
6.6.3	Przykład 6 – Średnia długość stażu nauczycieli matematyki	24
7	Analiza danych ICCS 2022	24
7.1	Przygotowanie danych	25
7.2	Przykład 1 – Średnie wyniki uczniów w zakresie wiedzy i rozumienia kwestii obywatelskich w podziale na płeć	27
7.3	Przykład 2 – Regresja liniowa: wpływ płci ucznia na wyniki w zakresie wiedzy i rozumienia kwestii obywatelskich	27
7.4	Przykład 3 – Partycypacja uczniów w życiu szkoły według dyrektorów szkół	29
7.4.1	Przykład 3A - Jak często uczniowie są zachęcani do włączania się w planowanie zajęć w klasie? Odsetek uczniów w szkołach, których dyrektorzy odpowiedzieli w określony sposób	29
7.4.2	Przykład 3B – Jak często uczniowie są zachęcani do włączania się w tworzenie szkolnych zasad i regulaminów? Odsetek uczniów w szkołach, których dyrektorzy odpowiedzieli w określony sposób	29
7.5	Przykład 4 - Odpowiedzi nauczycieli na pytanie: “Jak ważne dla bycia dobrym obywatelem w dorosłym życiu są następujące zachowania: Uczestniczenie w dyskusjach o polityce”	29
8	Analiza danych TALIS 2018	30
8.1	Przygotowanie danych	30
8.2	Analizy (TALISTCH - poziom nauczycieli)	31
8.2.1	Przykład 1 - Tabela rozkładów częstości płci nauczycieli	31
8.2.2	Przykład 2 - Średnia liczba godzin poświęcanych przez nauczycieli tygodniowo na komunikację i współpracę z rodzicami	31

8.2.3	Przykład 3 - Średnia liczba godzin poświęcanych przez nauczycieli tygodniowo na aktywności związane z rozwojem zawodowym	32
8.2.4	Przykład 4 - Regresja liniowa: wpływ możliwości aktywnego uczestnictwa w decyzjach dotyczących szkoły na ogólny poziom satysfakcji nauczycieli z wykonywanej pracy	32
8.3	Analizy (TALISCH - poziom szkół)	33
8.3.1	Przykład 5 - Średni staż pracy na stanowisku dyrektora szkoły w obecnym miejscu pracy (w latach)	33
8.3.2	Przykład 6 - Odsetek dyrektorów szkół, którzy zadeklarowali, że współpracują z nauczycielami przy rozwiązywaniu problemów z dyscypliną w klasie	34
9	Podsumowanie	34
10	Bibliografia	34

1 Wprowadzenie

Pakiet **Rrepest** w R (Ilizaliturri, Avvisati, & Keslair, 2025) jest rozwinięciem podejścia znanego z modułu **repest** w Stata, opracowanego pierwotnie dla analityków Organizacji Współpracy Gospodarczej i Rozwoju (OECD) (Avvisati & Keslair, 2014). Został zaprojektowany z myślą o ułatwieniu analizy danych z międzynarodowych badań edukacyjnych prowadzonych przez OECD oraz Międzynarodowe Stowarzyszenie Mierzenia Osiągnięć Szkolnych (IEA), takich jak:

- **PISA, PIAAC, TALIS, SSES** (badania OECD),
- **TIMSS, PIRLS, ICCS, ICILS** (badania IEA).

Pakiet umożliwia poprawną analizę wyników zgodnie z metodologią stosowaną w wymienionych wyżej badaniach, wspierając m.in.:

- obliczanie średnich, odsetków oraz częstości grupowanych,
- analizę korelacji i kowariancji oraz regresji liniowych,
- testy porównawcze między grupami oraz obliczanie miar rozproszenia.

Rrepest automatyzuje złożone elementy analizy danych z międzynarodowych badań edukacyjnych, uwzględniając stosowane w nich złożone schematy doboru próby oraz techniki skalowania wyników. Pakiet uwzględnia w obliczeniach **wagi statystyczne, wagi replikacyjne oraz wartości prawdopodobne (plausible values, PV)**, zapewniając prawidłowe oszacowanie niepewności pomiarowej. Dzięki temu pakiet ułatwia pracę z dużymi zbiorami danych i pozwala na szybsze dokonanie analiz zgodnych ze standardami OECD i IEA.

Dodatkowe zasoby

- **Pełna dokumentacja** - plik PDF zawierający opis funkcji pakietu oraz praktyczne przykłady jego zastosowania w analizie danych z międzynarodowych badań edukacyjnych.
- **README na CRAN** - skrócony przewodnik instalacyjny i opis głównych funkcji pakietu, dostępny na stronie pakietu w CRAN.
- **Repo/wiki z przykładami (OECD GitLab)** - strona, na której znajdziemy aktualizacje pakietu publikowane przez OECD oraz dodatkowe przykłady analiz.

1.1 Dlaczego warto używać Rrepest?

Zalety pakietu Rrepest

- **Automatyzacja:** upraszcza przetwarzanie złożonych danych, automatycznie uwzględniając metodologię badań OECD i IEA, taką jak wagi replikacyjne i wartości prawdopodobne (PV). Eliminuje to konieczność samodzielnej implementacji skomplikowanych formuł metodologicznych.
- **Wygoda:** funkcja `Rrepest()` oferuje przejrzystą składnię do obliczania statystyk opisowych, korelacji, regresji liniowej, testów różnic oraz generowania tabel wyników.
- **Elastyczność:** umożliwia analizy danych z wielu międzynarodowych badań edukacyjnych.
- **Wsparcie:** pakiet jest aktywnie wykorzystywany i stale rozwijany przez OECD.
- **Szybkość:** wykorzystuje obliczenia równoległe, rozdzielając obciążenie na wiele rdzeni procesora, co pozwala na dwukrotnie szybsze przetwarzanie danych w porównaniu do alternatywnych rozwiązań, szczególnie przy dużych zbiorach danych.

1.2 Ograniczenia Rrepest

Ważne ograniczenia pakietu Rrepest

- Pakiet wspiera jedynie podstawowe typy analiz: średnie, rozkłady częstości, testy różnic, korelacje i regresje liniowe i logistyczne. Nie obsługuje np. obliczania poziomów umiejętności (benchmarków), percentyli oraz bardziej zaawansowanych analiz (np. modeli wielopoziomowych).
- Regresja logistyczna wykonywana za pomocą parametru `est("log", ...)` jest wspierana tylko dla badań OECD (np. PISA, TALIS).
- W regresji liniowej przeprowadzanej za pomocą funkcji `Rrepest()` wszystkie predyktory są traktowane jako zmienne ciągłe – również wtedy, gdy zostały zakodowane jako czynniki (factor).
- Jeśli w danych pozostaną etykiety SPSS (value labels), nazwy kolumn w tabelach wynikowych będą zawierały etykiety kategorii i zostaną posortowane alfabetycznie co może utrudniać czytelność wyników.

1.3 Obsługiwane badania

Badanie (Organizacja)	Obsługiwane przez Rrepest
PISA (OECD)	
PIAAC (OECD)	
TALIS (OECD)	
SSES (OECD)	
TIMSS (IEA)	
PIRLS (IEA)	
ICCS (IEA)	
ICILS (IEA)	

2 Instalacja pakietów i przygotowanie danych do analizy

Aby rozpocząć pracę, należy jednorazowo zainstalować pakiet:

```
# instalacja pakietu Rrepest:
install.packages("Rrepest")

# instalacja dodatkowych pakietów do pracy z danymi
install.packages(c("haven", "tidyverse"))

# haven: pakiet do obsługi w R plików .sav, .sas7bdat, .dta
# tidyverse: zbiór pakietów ułatwiających analizę danych, m.in. dplyr, purrr,
# readr, stringr
```

Poniżej prezentujemy kilka dobrych praktyk ułatwiających korzystanie z pakietu.

 Dobre praktyki przy pracy z pakietem Rrepest:

- **Ujednolicenie pisowni nazw zmiennych:** Zamień wielkość liter w nazwach zmiennych na małe (np. `names(df) <- tolower(names(df))`), aby uniknąć problemów z odczytywaniem nazw przez funkcję `Rrepest()`. Niektóre jej argumenty (np. `over`) są wrażliwe na wielkość liter w podanych jako wartość nazwach zmiennych.
- **Sprawdzenie danych:** zweryfikuj strukturę zbioru i obecność braków danych:
 - struktura danych: `dplyr::glimpse(df)`, `summary(df)`,
 - liczba obserwacji w kategoriach danej zmiennej: `dplyr::count(df, zmienna)`,
 - liczba braków danych w kolumnach: (np. `colSums(is.na(df))`).
- **Powtarzalność:** Przechowuj kod w skryptach, dokumentuj ścieżki i transformacje, aby zapewnić powtarzalność analiz
- **Porównanie:** Porównaj wyniki analiz z oficjalnymi raportami OECD/IEA lub narzędziem **IEA IDB Analyzer**, aby upewnić się, że są zgodne z metodologią badania.

3 Składnia i kluczowe opcje funkcji `Rrepest()`

Podstawowa składnia funkcji wraz z jej głównymi argumentami

```

Rrepest(
  data = <zbiór danych>,
  svy = <nazwa badania ("ALL"|"IALS"|"IELS"|"PIAAC"|"PIRLS"|"PISA"|
"PISA00S"|"SSES"|"TALIS" ("TALISSCH"/"TALISTCH")|"TALIS3S" ("TALISEC_STAFF"/
"TALISEC_LEADER")|"TIMSS"|"ICCS" (ICCS_T)"|"ICILS"|"SVY" (własne/
niestandardowe badanie))>,
  est = est(
    <"mean"|"var"|"std"|"quant"|"iqr"|"freq"|"corr"|"lm"|"log"|"cov"|"gen">,
    target = <zmienna>,
    regressor = <zmienna | wektor zmiennych>
    # argument "regressor" podajemy dla estymatorów "lm" i "log";
    # przy użyciu estymatora "gen" podstawiamy własny model, bez konieczności
    # używania argumentów "target" i "regressor"
  ),
  by = <zmienna | wektor zmiennych>,
  over = <zmienna | wektor zmiennych>,
  test = TRUE/FALSE,
  n.pvs = <liczba wartości prawdopodobnych (PV)>,
  cm.weights = c(<waga główna>, <wagi replikacyjne_1:K>),
  var.factor = <współczynnik wariancji>,
  show_na = TRUE/FALSE
)

```

Najważniejsze argumenty funkcji:

- **svy** - nazwa badania, które bierzemy pod uwagę w analizie.
- **est()** – wbudowane estymatory to "mean", "var", "std", "quant", "iqr", "freq", "corr", "lm", "log", "cov", oraz ogólny "gen" do uruchamiania własnych modeli z R.
- **target** – pojedyncza zmienna lub wielokrotne imputacje PV przez zastosowanie składni z symbolem @ (np. PVREAD@, PVNUM@, ASMMAT0@). Składnia z symbolem @ może być też używana przy podawaniu zmiennych PV w parametrach **by**, **over** i **regressor**.
- **by** – osobne estymacje/tabele dla wskazanych zmiennych.
- **over + test=TRUE** – analiza grup łącznie i raport testów różnic między poziomami zmiennej wskazanej w argumencie **over**.
- **n.pvs** – liczba PV wykorzystywana przy uśrednianiu wyników dla wartości prawdopodobnych (domyślnie **Rrepest** bierze pod uwagę 5 PV).
- **cm.weights** – główna waga i komplet wag replikacyjnych (np. **totwgt**, **jr1:jrK**). Ustawienie tego parametru jest konieczne przy niektórych analizach, w których nie korzystamy z wag domyślnie uwzględnianych przez funkcję **Rrepest()**.
- **var.factor** – współczynnik wariancji zgodny z zastosowanym schematem doboru próby. Ustawienie tego parametru jest konieczne przy niektórych analizach, w których nie

korzystamy z wag domyślnie uwzględnianych przez funkcję `Rrepest()`.

- `show_na` – w przypadku ustawienia wartości tego parametru na “TRUE” w raportach częstości braki danych uwzględniane są jako osobna kategoria.

by vs over

- **by** – wykonuje analizę osobno dla każdej grupy, traktując je jako niezależne zbiory danych. **Nie umożliwia bezpośredniego testowania różnic między grupami**
- **over w połączeniu z test=TRUE** – analizuje wszystkie grupy łącznie, automatycznie obliczając **różnice między nimi** i błędy standardowe.

3.1 Struktura danych w międzynarodowych badaniach edukacyjnych

Aby `Rrepest` działał poprawnie, kluczowe zmienne w zbiorze danych takie jak PV oraz wagi analityczne muszą mieć określoną strukturę nazw, odpowiadającą konwencjom w poszczególnych badaniach w obrębie danego cyklu badawczego.

3.1.1 Nazwy zmiennych z wartościami prawdopodobnymi (PV)

Wartości prawdopodobne (PV) to zestaw wielokrotnych imputacji niewidocznych (niedających się zmierzyć bezpośrednio) cech (np. umiejętności matematycznych), które pozwalają na lepsze oszacowanie błędów pomiaru. Funkcja `Rrepest()` rozpoznaje te wartości przez składnię zawierającą symbol @ w nazwie zmiennej (np. `pvmath`, `pvmread`, `pvciv`) i zakłada, że dostępne są wielokrotne jej imputacje (np. `pvm1math`, ..., `pvmKmath`, gdzie K to liczba PV w danym badaniu).

Ustawienie liczby PV

- Domyślnie funkcja `Rrepest()` przyjmuje 5 jako liczbę dostępnych imputacji.
- W przypadku, gdy w analizowanym badaniu jest więcej wartości prawdopodobnych (w badaniu PISA w cyklach od 2015 roku liczba PV wynosi 10), należy dodatkowo zdefiniować poprawną liczbę imputacji za pomocą argumentu `n.pvs` (np. `n.pvs = 10`).

3.1.2 Nazwy zmiennych wag analitycznych

Wagi analityczne są drugim rodzajem kluczowych zmiennych w międzynarodowych badaniach edukacyjnych. Aby funkcja `Rrepest()` działała poprawnie, nazwy tych zmiennych muszą przyjąć

postać odpowiednią dla badania wybranego do analizy. W każdym badaniu występuje zmienna Wagi głównej (total/final weight), np. `wfstwt` oraz wagi replikacyjne (replicate weights), np. `wfsturwt1, ..., wfsturwt80`. Nazwy tych zmiennych oraz liczby replik są różne w poszczególnych badaniach. W większości przypadków funkcja `Rrepest()` pobiera je automatycznie ze zbioru danych na podstawie nazwy badania podanej w argumencie `svy`.

i Przykładowe domyślne ustawienia wag analitycznych w funkcji `Rrepest()`

- **PISA** – waga główna `wfstwt` oraz 80 replik `wfsturwt1, ..., wfsturwt80` (wagi uczniowskie)
- **ICCS/ICILS** – waga główna `totwgts` oraz 75 replik `srwgt1, ..., srwgt75` (wagi uczniowskie)

! Ważne

- W przypadku badań TIMSS i PIRLS (oraz innych badań wykorzystujących schemat ważenia Jackknife Repeated Replication), konieczne jest samodzielne przeliczenie wag replikacyjnych i dodanie ich do zbioru danych. Opisujemy jak to zrobić w części praktycznej poradnika.
- W niektórych badaniach rozróżnia się schematy badań zależnie od analizowanych grup respondentów. Przykładowo, w badaniu TALIS w argumencie `'svy'` możemy podać `"TALISTCH"`, jeśli analizujemy nauczycieli, lub `"TALISSCH"`, jeśli dokonujemy analiz na zbiorze danych dotyczących szkół. Podobnie, w badaniu ICCS możemy podać w argumencie `'svy'` nazwę badania z przyrostkiem `'_T'` (`"ICCS_T"`), jeżeli analizujemy dane nauczycieli. `Rrepest` automatycznie zastosuje odpowiednie wagi analityczne.
- Metodologia badań TIMSS i PIRLS uległa zmianie w cyklach realizowanych po 2011 roku. W cyklach przeprowadzonych do 2011 roku włącznie stosowano 150 wag replikacyjnych oraz jedną wartość PV, natomiast w późniejszych cyklach – 250 wag replikacyjnych i pięć wartości PV.

4 Pobieranie danych

Dane i dokumentacja (np. opisy nazw zbiorów i zmiennych) z badań dostępne są na poniższych stronach:

- **PISA**: <https://www.oecd.org/pisa/data/>

- **TIMSS/PIRLS/ICCS/ICILS:** <https://www.iea.nl/data-tools/repository>
- **PIAAC:** <https://www.oecd.org/skills/piaac/data/>
- **TALIS:** <https://www.oecd.org/en/about/programmes/talis.html#data>
- **SSES:** <https://www.oecd.org/en/about/programmes/oecd-survey-on-social-and-emotional-skills.html#data>

W przypadku badań OECD przed pobraniem zbioru należy wypełnić krótką ankietę.

4.1 Struktura plików danych

Przed rozpoczęciem analizy dane z badań międzynarodowych muszą zostać zaimportowane do środowiska R, co wymaga zrozumienia złożonej struktury plików je zawierających. Struktura ta jest różna pomiędzy badaniami OECD i IEA.

4.1.1 Struktura danych IEA

Zbiory IEA są zazwyczaj podzielone na dużą liczbę plików, pogrupowanych według kraju, poziomu klasy oraz zastosowanego narzędzia badawczego. Przykładowo po ściągnięciu danych z badania TIMSS 2023 dla klasy 4 w folderze zobaczymy ponad 500 plików.

i Nazewnictwo plików w badaniach IEA, na przykładzie badania TIMSS

Przykładowo: Plik `asapolm8.sav` zawiera dane uczniów z Polski z badania TIMSS 2023 dla klasy 4 w formacie `.sav`

Gdzie:

- `asa`: odpowiedzi na zadania i wyniki uczniów klasy 4
- `pol`: kod kraju (Polska)
- `m8`: cykl badania (TIMSS 2023)

Pierwsza litera w nazwie pliku wskazuje poziom klasy:

- `a` – klasa 4
- `b` – klasa 8

Dalsze litery określają typ danych:

- `asa/bsa` – wyniki uczniów oraz wartości prawdopodobne (PV)
- `asp/bsp` – dane procesowe (np. czasy odpowiedzi)
- `ash` – dane z kwestionariusza rodzica

- **asg/bsg** – dane z kwestionariusza ucznia
- **acg/bcg** – dane z kwestionariusza szkoły
- **atg/btg** – dane z kwestionariusza nauczyciela

4.1.2 Struktura danych OECD

W przypadku badań OECD dane z różnych krajów są połączone w jeden zbiorczy plik (często bardzo duży), bez podziału na osobne pliki krajowe. Pliki są podzielone według cyklu badania oraz typu danych.

i Nazewnictwo plików w badaniach OECD, na przykładzie badania PISA

Przykład: Plik **CY08MSP_STU_QQQ.sav** zawiera dane z kwestionariuszy uczniów z wszystkich krajów z badania realizowanego w roku 2022.

Gdzie:

- **CY08** – cykl badania (tu: cykl 8, przeprowadzony w 2022 roku)
- **MSP** – Main Study (badanie główne)
- **STU_QQQ** – dane uczniów

Inne oznaczenia:

- **SCH_QQQ** – kwestionariusze szkół
- **TCH_QQQ** – kwestionariusze nauczycieli
- **STU_COG** – wyniki testów kognitywnych uczniów (czytanie, matematyka, nauki przyrodnicze itp.)
- **STU_FLT** – wyniki testów z edukacji finansowej
- **STU_ICT** – kwestionariusz dotyczący technologii informacyjno-komunikacyjnych
- **STU_WBQ** – kwestionariusz dobrostanu uczniów

5 Analiza danych PISA 2022

5.1 Przygotowanie danych

```
# Krok 1: wskazanie folderu z plikami SPSS
dir_pisa_2022 <- "C:/DATA/PISA 2022/Data_SPSS"

# Krok 2: wczytanie danych uczniowskich (STU_QQQ)
```

```
data_students <- read_sav(paste0(dir_pisa_2022, "/CY08MSP_STU_XXX.sav"))

# Krok 3: Wybór krajów do analizy (Australia, Kanada, Peru, Polska) i
# filtrowanie zbioru danych
countries <- c("AUS", "CAN", "PER", "POL")
pisa_2022 <- filter(data_students, CNT %in% countries)

# Krok 4: zmiana wielkości liter w nazwach zmiennych na małe:
names(pisa_2022) <- tolower(names(pisa_2022))
```

5.2 Przykład 1 – średnia i odchylenie standardowe wyników umiejętności czytania według kraju i płci

```
Analysis_01 <- Rrepest(
  data = pisa_2022,
  svy = "PISA",
  est = est(c("mean", "std"), target = "pv@read"),
  by = c("cnt", "st004d01t"),
  n.pvs = 10 #`Rrepest()` domyślnie używa 5 PV. W PISA 2022
             # należy ustawić `n.pvs = 10`
)
print(Analysis_01)
```

5.3 Przykład 2 – Tabela rozkładów częstości płci uczniów

```
Analysis_02 <- Rrepest(
  data = pisa_2022,
  svy = "PISA",
  est = est("freq", target = "st004d01t"),
  by = "cnt",
  show_na = TRUE
)
print(Analysis_02, width = 200)
```

5.4 Przykład 3 – Regresja liniowa: analiza wpływu statusu społeczno–ekonomicznego rodziny na osiągnięcia ucznia w dziedzinie matematyki:

```
Analysis_03 <- Rrepest(  
  data = pisa_2022,  
  svy = "PISA",  
  by = "cnt",  
  est = est("lm", target = "pv@math", regressor = "escs"),  
  n.pvs = 10,  
  show_na = TRUE  
)  
print(Analysis_03, width = 200)
```

Przykładowy kod poprawiający czytelność tabeli wynikowej

```
Table_03<- Analysis_03 %>%  
  transmute(  
    Country = cnt,  
    Intercept_Estimate = rowMeans(select(., starts_with("b.reg_pv") &  
      ends_with("intercept"))),  
    Intercept_SE = rowMeans(select(., starts_with("se.reg_pv") &  
      ends_with("intercept"))),  
    Intercept_t = Intercept_Estimate / Intercept_SE,  
  
    ESCS_Estimate = rowMeans(select(., starts_with("b.reg_pv") &  
      ends_with("escs"))),  
    ESCS_SE = rowMeans(select(., starts_with("se.reg_pv") &  
      ends_with("escs"))),  
    ESCS_t = ESCS_Estimate / ESCS_SE,  
  
    R2_Estimate = rowMeans(select(., starts_with("b.reg_pv") &  
      ends_with("rsqr"))),  
    R2_SE = rowMeans(select(., starts_with("se.reg_pv") &  
      ends_with("rsqr"))),  
    R2_t = R2_Estimate / R2_SE  
  )  
  
make_reg_table <- function(row) {  
  data.frame(  
    Estimate = c(row$Intercept_Estimate,
```

```

        row$ESCS_Estimate,
        row$R2_Estimate),
`Std. Error` = c(row$Intercept_SE,
        row$ESCS_SE,
        row$R2_SE),
`t value`    = c(row$Intercept_t,
        row$ESCS_t,
        row$R2_t),
row.names = c("(Intercept)", "ESCS", "R-squared")
)
}

final_table_03 <- setNames(
  lapply(1:nrow(Table_03),
    function(i) make_reg_table(Table_03[i, ])),
  Table_03$Country
)

print(final_table_03)

```

5.5 Przykład 4 – Regresja logistyczna: wpływ statusu społeczno-ekonomicznego rodziny na osiągnięcia ucznia w dziedzinie matematyki (uzyskanie wyniku na poziomie co najmniej 626 punktów):

```

# Na potrzeby analizy z wykorzystaniem regresji logistycznej konieczne jest
# utworzenie nowej zmiennej przyjmującej wartości "1" lub "0", w zależności
# od tego czy dany uczeń osiągnął wynik równy lub wyższy od wartości 626 pkt
# (dla każdej imputacji PV tworzymy osobną zmienną).

for (i in 1:10) {
  varname <- paste0("pv", i, "math")
  newvar <- paste0("y", i)
  pisa_2022[[newvar]] <- ifelse(pisa_2022[[varname]] >= 626, 1, 0)
}

Analysis_04 <- Rrepest(
  data = pisa_2022,
  svy = "PISA",
  est = est("log", target = "y@", regressor = "escs"),

```

```

    n.pvs = 10,
    by     = "cnt"
  )
  print(Analysis_04, width = 200)

```

Przykładowy kod poprawiający czytelność tabeli wynikowej

```

Table_04 <- Analysis_04 %>%
  transmute(
    Country    = cnt,
    Coef        = rowMeans(select(., starts_with("b.log") &
                                ends_with("intercept"))),
    Std_Error   = rowMeans(select(., starts_with("se.log") &
                                ends_with("intercept"))),
    t_value     = round(Coef / Std_Error, 2),
    ESCS        = rowMeans(select(., starts_with("b.log") &
                                ends_with("escs"))),
    ESCS_SE     = rowMeans(select(., starts_with("se.log") &
                                ends_with("escs"))),
    ESCS_t      = round(ESCS / ESCS_SE, 2),
    OR          = round(exp(Coef), 2),
    CI95low     = round(exp(Coef - 1.96 * `Std_Error`), 2),
    CI95up      = round(exp(Coef + 1.96 * `Std_Error`), 2),
    OR_ESCS     = round(exp(ESCS), 2),
    CI95low_ESCS = round(exp(ESCS - 1.96 * `ESCS_SE`), 2),
    CI95up_ESCS = round(exp(ESCS + 1.96 * `ESCS_SE`), 2)
  )

make_logreg_table <- function(row) {
  data.frame(
    Coef          = c(row$Coef, row$ESCS),
    `Std. Error` = c(row$Std_Error, row$ESCS_SE),
    `t value`    = c(row$t_value, row$ESCS_t),
    OR           = c(row$OR, row$OR_ESCS),
    CI95low      = c(row$CI95low, row$CI95low_ESCS),
    CI95up       = c(row$CI95up, row$CI95up_ESCS),
    row.names    = c("(Intercept)", "ESCS")
  )
}

final_table_04 <- setNames(lapply(1:nrow(Table_04),

```

```
function(i) make_logreg_table(Table_04[i, ]),  
Table_04$Country)  
  
print(final_table_04)
```

6 Analiza danych TIMSS 2023 (klasa 4)

6.1 Przygotowanie danych krok po kroku

Przygotowanie danych TIMSS do analizy za pomocą funkcji `Rrepest()` jest procesem wielo-etapowym. Wynika to zarówno z charakterystyki struktury zbioru danych jak i metodologii badania TIMSS.

6.1.1 Połączenie danych

```
# Krok 1: wskazanie folderu z plikami SPSS  
dir_timss_2023 <- "C:/DATA/TIMSS2023_IDB_SPSS_G4/2_Data Files/SPSS Data"  
  
# Krok 2: utworzenie list plików dla wybranych krajów (Armenia, Australia,  
# Bahrajn, Polska) oraz poszczególnych zbiorów danych:  
  
# Pliki student achievement (ASA), zawierające wyniki testów umiejętności  
timss_2023_asa_files <- list.files(dir_timss_2023,  
  pattern = ".*ASA(POL|AUS|ARM|BHR).*\.\sav$",  
  ignore.case = TRUE, full.names = TRUE)  
  
# Pliki student context (ASG), zawierające dane z ankiety uczniowskiej  
timss_2023_asg_files <- list.files(dir_timss_2023,  
  pattern = ".*ASG(POL|AUS|ARM|BHR).*\.\sav$",  
  ignore.case = TRUE, full.names = TRUE)  
  
# Pliki school context (ACG), zawierające dane z ankiety dyrektorów szkół  
timss_2023_acg_files <- list.files(dir_timss_2023,  
  pattern = ".*ACG(POL|AUS|ARM|BHR).*\.\sav$",  
  ignore.case = TRUE, full.names = TRUE)
```

```
# Pliki home context (ASH), zawierające dane z ankiety rodziców
timss_2023_ash_files <- list.files(dir_timss_2023,
  pattern = ".*ASH(POL|AUS|ARM|BHR).*\\.sav$",
  ignore.case = TRUE, full.names = TRUE)

# Krok 3: Połączenie danych z ankiet z wybranych krajów z wykorzystaniem
# wcześniej utworzonych list plików
timss_2023_asa <- timss_2023_asa_files %>% map(read_sav) %>%
  bind_rows()
timss_2023_asg <- timss_2023_asg_files %>% map(read_sav) %>%
  bind_rows()
timss_2023_acg <- timss_2023_acg_files %>% map(read_sav) %>%
  bind_rows()
timss_2023_ash <- timss_2023_ash_files %>% map(read_sav) %>%
  bind_rows()
```

! Ważne

W przypadku łączenia zbiorów z różnych kwestionariuszy w parametrze "by" funkcji `left_join()` podajemy wszystkie zmienne, które powtarzają się w łączonych zbiorach danych (w zależności od łączonych baz danych mogą to być takie zmienne jak identyfikator szkoły lub ucznia (odpowiednio np. "IDSCHOOL" i "IDSTUD") ale także wartości PV). W przeciwnym razie funkcja `left_join()` utworzy duplikaty kolumn zawierających te same zmienne, nadając nazwom tych zmiennych przyrostki (np. "zmienna01.x", "zmienna01.y"). Może to stanowić utrudnienie przy prowadzeniu analiz.

```
# Krok 4: Połączenie zbiorów ze wszystkich kwestionariuszy
timss_2023 <- left_join(
  timss_2023_asa,
  select(timss_2023_acg, -any_of(names(timss_2023_asa)),
    CTY,
    IDSCHOOL),
  by = c("CTY", "IDSCHOOL")
) %>% left_join(
  select(timss_2023_asg, -any_of(names(timss_2023_asa)),
    CTY,
    IDSCHOOL,
    IDSTUD),
  by = c("CTY", "IDSCHOOL", "IDSTUD")
) %>% left_join(
  select(timss_2023_ash, -any_of(names(timss_2023_asa)),
    CTY,
```

```

                                IDCNTY,
                                IDSCHOOL,
                                IDSTUD),
  by = c("CTY", "IDCNTY", "IDSCHOOL", "IDSTUD")
)

```

6.1.2 Utworzenie 250 wag replikacyjnych zgodnie z zastosowaną w badaniu TIMSS metodą Jackknife Repeated Replication (JRR)

```

# Krok 5: budowa 250 wag replikacyjnych metodą JRR
for (i in 1:125) {
  j <- 125 + i
  timss_2023 <- timss_2023 %>%
    mutate(!paste0("jr", i) := case_when(
      JKZONE == i & JKREP == 1 ~ 2 * TOTWGT,
      JKZONE == i & JKREP == 0 ~ 0,
      TRUE ~ TOTWGT
    )) %>%
    mutate(!paste0("jr", j) := case_when(
      JKZONE == i & JKREP == 0 ~ 2 * TOTWGT,
      JKZONE == i & JKREP == 1 ~ 0,
      TRUE ~ TOTWGT
    ))
}

```

6.1.3 Zmiana wielkości liter w nazwach zmiennych

```

# Krok 6: zmiana wielkości liter w nazwach zmiennych na małe:
names(timss_2023) <- tolower(names(timss_2023))

```

! Ważne

W analizach TIMSS/PIRLS: należy użyć parametru custom weights **cm.weights = c("totwgt", paste0("jr", 1:250))** wskazując wagę główną **totwgt** oraz utworzone wcześniej wagi replikacyjne (**jr1**, ..., **jr250**). Dla poprawnego przeliczenia błędów standardowych uwzględniających zastosowane wagi replikacyjne, konieczne jest także podanie wartości argumentu współczynnika wariancji: **var.factor = 125**. Wartość współczynnika wariancji zależy od zastosowanego schematu doboru próby. Aby zapewnić poprawność wykonywanych analiz, zapoznaj się z informacjami o metodzie tworzenia wag

replikacyjnych zastosowanej w danym cyklu danego badania.

6.2 Przykład 1 – Średni wynik z matematyki według kraju i płci

```
Analysis_01 <- Rrepest(  
  data = timss_2023,  
  svy = "TIMSS",  
  cm.weights = c("totwgt", paste0("jr", 1:250)),  
  est = est(c("mean", "std"), target = "asmmat0@"),  
  by = c("cty", "itsex"),  
  var.factor = 125  
)  
print(Analysis_01)
```

6.3 Przykład 2 – Średni wynik z matematyki według kraju i płci, z zastosowaniem parametru over i pokazaniem różnicy wyników pomiędzy płciami (chłopcy – dziewczęta) w poszczególnych krajach

```
Analysis_02 <- Rrepest(  
  data = timss_2023,  
  svy = "TIMSS",  
  cm.weights = c("totwgt", paste0("jr", 1:250)),  
  est = est("mean", target = "asmmat0@"),  
  by = "cty",  
  over = "itsex",  
  test = TRUE,  
  var.factor = 125  
)  
print(Analysis_02, width = 200)
```

6.4 Przykład 3 – Tabela rozkładów częstości płci uczniów

```
Analysis_03 <- Rrepest(  
  data = timss_2023,  
  svy = "TIMSS",  
  cm.weights = c("totwgt", paste0("jr", 1:250)),
```

```

est = est("freq", "itsex"),
by = "cty",
show_na = TRUE,
var.factor = 125
)
print(Analysis_03)

```

6.5 Przykład 4 – Regresja liniowa: wpływ płci ucznia oraz braku wczesnych aktywności związanych z liczeniem na osiągnięcia uczniów w dziedzinie matematyki

```

Analysis_04 <- Rrepest(
  data = timss_2023,
  svy = "TIMSS",
  cm.weights = c("totwgt", paste0("jr", 1:250)),
  by = "cty",
  est = est("lm", target = "asmmat0@", regressor = c("itsex", "asbh01k")),
  var.factor = 125
)
print(Analysis_04)

```

Przykładowy kod poprawiający czytelność tabeli wynikowej

```

Table_04 <- Analysis_04 %>%
  transmute(
    Country = cty,
    Intercept_Estimate = rowMeans(select(., starts_with("b.reg_asmmat") &
      ends_with("intercept"))),
    Intercept_SE = rowMeans(select(., starts_with("se.reg_asmmat") &
      ends_with("intercept"))),
    Intercept_t = Intercept_Estimate / Intercept_SE,
    ITSEX_Estimate = rowMeans(select(., starts_with("b.reg_asmmat") &
      ends_with("itsex"))),
    ITSEX_SE = rowMeans(select(., starts_with("se.reg_asmmat") &
      ends_with("itsex"))),
    ITSEX_t = ITSEX_Estimate / ITSEX_SE,
    ASBH01K_Estimate = rowMeans(select(., starts_with("b.reg_asmmat") &
      ends_with("asbh01k"))),
    ASBH01K_SE = rowMeans(select(., starts_with("se.reg_asmmat") &
      ends_with("asbh01k"))),

```

```

    ASBH01K_t      = ASBH01K_Estimate / ASBH01K_SE,
    R2_Estimate    = rowMeans(select(., starts_with("b.reg_asmmat") &
                                   ends_with("rsqr"))),
    R2_SE          = rowMeans(select(., starts_with("se.reg_asmmat") &
                                   ends_with("rsqr"))),
    R2_t           = R2_Estimate / R2_SE
  )

make_reg_table <- function(row) {
  data.frame(
    Estimate      = c(row$Intercept_Estimate,
                      row$ITSEX_Estimate,
                      row$ASBH01K_Estimate,
                      row$R2_Estimate),
    `Std. Error` = c(row$Intercept_SE,
                      row$ITSEX_SE,
                      row$ASBH01K_SE,
                      row$R2_SE),
    `t value`     = c(row$Intercept_t,
                      row$ITSEX_t,
                      row$ASBH01K_t,
                      row$R2_t),
    row.names = c("(Intercept)", "ITSEX", "ASBH01K", "R-squared")
  )
}

final_table_04 <- setNames(lapply(1:nrow(Table_04),
                                   function(i) make_reg_table(Table_04[i, ])),
                           Table_04$Country)

print(final_table_04)

```

6.6 Analizy na danych nauczycieli matematyki (TIMSS 2023)

Aby analizować dane dla nauczycieli musimy połączyć pliki z prefiksem ATG (teacher context) zawierające dane z ankiety nauczycielskiej z plikami z prefiksem AST (student-teacher linkage), gdyż w tym zbiorze znajdują się zmienne z wagami głównymi przypisanymi do nauczycieli ("TCHWGT" - wszyscy nauczyciele, "MATWGT" - nauczyciele matematyki, "SCIWGT" - nauczyciele nauk przyrodniczych)

6.6.1 Przygotowanie danych i budowa wag replikacyjnych dla nauczycieli zgodnie z zastosowaną w badaniu TIMSS 2023 metodą Jackknife Repeated Replication (JRR)

```
# Krok 1: Wczytanie danych z ankiet nauczycieli i uczniów dla wybranych krajów

# Pliki ATG - teacher context
# Pliki AST - student-teacher linkage

timss_2023_atg_files <- list.files(dir_timss_2023,
                                   pattern = ".*ATG(POL|AUS|ARM|BHR).*\\.sav$",
                                   ignore.case = TRUE,
                                   full.names = TRUE)

timss_2023_ast_files <- list.files(dir_timss_2023,
                                   pattern = ".*AST(POL|AUS|ARM|BHR).*\\.sav$",
                                   ignore.case = TRUE,
                                   full.names = TRUE)

timss_2023_atg <- timss_2023_atg_files %>% map(read_sav) %>% bind_rows()
timss_2023_ast <- timss_2023_ast_files %>% map(read_sav) %>% bind_rows()

# Krok 2: Połączenie baz danych
timss_2023_teacher <- left_join(
  timss_2023_atg,
  select(timss_2023_ast, -any_of(names(timss_2023_atg)),
        CTY,
        IDCNTY,
        IDSCHOOL,
        IDTEACH,
        IDTEALIN),
  by = c("CTY", "IDCNTY", "IDSCHOOL", "IDTEACH", "IDTEALIN")
)

# Krok 3: Stworzenie 250 wag replikacyjnych z wykorzystaniem wagi nauczycieli
# matematyki (MATWGT)

for (i in 1:125) {
  j <- 125 + i
  timss_2023_teacher <- timss_2023_teacher %>%
    mutate(!!paste0("jr", i) := case_when(
      JKZONE == i & JKREP == 1 ~ 2 * MATWGT,
      JKZONE == i & JKREP == 0 ~ 0,

```

```

    TRUE ~ MATWGT
  )) %>%
  mutate(!paste0("jr", j) := case_when(
    JKZONE == i & JKREP == 0 ~ 2 * MATWGT,
    JKZONE == i & JKREP == 1 ~ 0,
    TRUE ~ MATWGT
  ))
}

# Krok 4: Pozostawienie w zbiorze do dalszych analiz tylko nauczycieli
# matematyki (usuwamy wszystkie wiersze, gdzie zmienna "MATWGT" przyjmuje
# wartość NA)
timss_2023_teacher <- timss_2023_teacher %>% filter(!is.na(MATWGT))

# Krok 5: Zmiana wielkości liter w nazwach zmiennych
names(timss_2023_teacher) <- tolower(names(timss_2023_teacher))

```

! Ważne

W analizach dotyczących nauczycieli matematyki w badaniu TIMSS 2023 należy użyć parametru custom weights **cm.weights = c("matwgt", paste0("jr", 1:250))** wskazując wagę główną **matwgt** oraz utworzone wcześniej wagi replikacyjne (**jr1, ..., jr250**). Dla poprawnego przeliczenia błędów standardowych uwzględniających zastosowane wagi, konieczne jest także podanie wartości argumentu współczynnika wariancji: **var.factor = 125**.

6.6.2 Przykład 5 – Odsetki nauczycieli matematyki według wieku

```

# rekodowanie wieku do zmiennej katagorycznej
timss_2023_teacher <- timss_2023_teacher %>%
  dplyr::mutate(
    atbg03 = factor(atbg03, levels = 1:6,
      labels = c(
        "Under 25",
        "25-29",
        "30-39",
        "40-49",
        "50-59",
        "60 or more"))
  )

```

```

Analysis_05 <- Rrepest(
  data = timss_2023_teacher,
  svy = "TIMSS",
  cm.weights = c("matwgt", paste0("jr", 1:250)),
  est = est("freq", target = "atbg03"),
  by = "cty",
  show_na = TRUE,
  var.factor = 125
)

print(Analysis_05)

```

6.6.3 Przykład 6 – Średnia długość stażu nauczycieli matematyki

```

Analysis_06 <- Rrepest(
  data = timss_2023_teacher,
  svy = "TIMSS",
  cm.weights = c("matwgt", paste0("jr", 1:250)),
  est = est("mean", target = "atbg01"),
  by = "cty",
  var.factor = 125
)

print(Analysis_06)

```

7 Analiza danych ICCS 2022

! Ważne

Część krajów uczestniczących w badaniu ICCS 2022 po raz pierwszy przeprowadziła je w formie testów komputerowych. W krajach tych zrealizowano dodatkowy komponent badania w formie ankiet papierowych, tzw. „bridge study”. Dane z próby „bridge” nie są uwzględniane w raportowaniu wyników ICCS 2022, dlatego w analizach pomijamy je, wybierając wyłącznie pliki z przyrostkiem „C4” w nazwie.

7.1 Przygotowanie danych

```
# Krok 1: wskazanie folderu z plikami SPSS
dir_iccs_2022 <- "C:/DATA/ICCS 2022/SPSS Data/ICCS_2022_G8"

# Krok 2: utworzenie list plików dla wybranych krajów (Chorwacja, Hiszpania,
# Polska, Rumunia, Szwecja) oraz poszczególnych zbiorów danych

# Uwaga: pomijamy pliki z edycji "bridge", wybierając pliki z przyrostkiem "C4"
# w nazwie

# Pliki Student Civic Knowledge (ISA), zawierające wyniki dotyczące kompetencji
# obywatelskich
iccs_isa_files <- list.files(dir_iccs_2022,
  pattern = ".*ISA(POL|HRV|ESP|SWE|ROU)C4.*\\.sav$",
  ignore.case = TRUE, full.names = TRUE)

# Pliki International Student Questionnaire (ISG), zawierające dane z ankiety
# uczniowskiej
iccs_isg_files <- list.files(dir_iccs_2022,
  pattern = ".*ISG(POL|HRV|ESP|SWE|ROU)C4.*\\.sav$",
  ignore.case = TRUE, full.names = TRUE)

# Pliki School Questionnaire (ICG), zawierające dane z ankiety
# dyrektorów szkół
iccs_icg_files <- list.files(dir_iccs_2022,
  pattern = ".*ICG(POL|HRV|ESP|SWE|ROU)C4.*\\.sav$",
  ignore.case = TRUE, full.names = TRUE)

# Pliki Teacher Questionnaire (ITG), zawierające dane z ankiety
# nauczycielskiej
iccs_itg_files <- list.files(dir_iccs_2022,
  pattern = ".*ITG(POL|HRV|ESP|SWE|ROU)C4.*\\.sav$",
  ignore.case = TRUE, full.names = TRUE)

# Krok 3: Połączenie danych z ankiet z wybranych krajów z wykorzystaniem
# wcześniej utworzonych list plików
iccs_2022_isa <- iccs_isa_files %>% map(read_sav) %>% bind_rows()
iccs_2022_isg <- iccs_isg_files %>% map(read_sav) %>% bind_rows()
iccs_2022_icg <- iccs_icg_files %>% map(read_sav) %>% bind_rows()
iccs_2022_itg <- iccs_itg_files %>% map(read_sav) %>% bind_rows()
```

! Ważne

W przypadku badania ICCS 2022, przy łączeniu zbiorów danych zawierających wyniki dotyczące kompetencji obywatelskich uczniów (pliki z prefiksem ISA) oraz wyniki ankiety uczniowskiej (pliki z prefiksem ISG) uwzględniamy w argumencie `by` funkcji `left_join()` wartości PV, główną zmienną wagową oraz wagi replikacyjne uczniów. Jest to konieczne, ponieważ zmienne te występują w obydwu zbiorach.

```
# Krok 4: Połączenie zbiorów danych dotyczących uczniów (wyniki dotyczące
# kompetencji obywatelskich oraz dane z ankiety uczniowskiej) oraz
# dyrektorów szkół
```

```
iccs_2022 <- left_join(
  iccs_2022_isa,
  iccs_2022_isg,
  by = c("COUNTRY", "IDSCHOOL", "IDSTUD", "std_GENDER",
         "TOTWGTS", paste0("PV", 1:5, "CIV"), paste0("SRWGTO", 1:9),
         paste0("SRWGT", 10:75))
) %>% left_join(
  iccs_2022_icg,
  by = c("COUNTRY", "IDSCHOOL")
)
```

! Ważne

W badaniu ICCS, możemy traktować zbiór nauczycielski jako niezależny od zbioru uczniowskiego i badać nauczycieli z wykorzystaniem wag nauczycielskich.

```
# Nie łączymy danych nauczycieli z innymi zbiorami, ponieważ nie jest to
# potrzebne w naszych przykładowych analizach
iccs_2022_teacher <- iccs_2022_itg
```

```
# Krok 5: Zmiana wielkości liter w nazwach zmiennych
names(iccs_2022) <- tolower(names(iccs_2022))
names(iccs_2022_teacher) <- tolower(names(iccs_2022_teacher))
```

! Ważne

W wypadku badania ICCS, funkcja `Rrepest()` oczekuje, że zmienne wag replikacyjnych przyjmują nazwy bez zer prowadzących w przypadku replik o numeracji od 1 do 9 (np. "srwgt1,..., srwgt9" lub "trwgt1,..., trwgt9"). W udostępnionym przez IEA zbiorze danych

ICCS 2022 nazwy zmiennych replikacyjnych zawierają zera prowadzące, przyjmując postać “srwgt01,..., srwgt09”, “trwgt01,..., trwgt09”. Aby funkcja zadziałała poprawnie, konieczna jest samodzielna zmiana nazw tych zmiennych.

```
# Krok 6: usunięcie prowadzących zer w nazwach wag replikacyjnych
# w zbiorach uczniów i nauczycieli
colnames(iccs_2022) <- gsub("^srwgt0([1-9])$", "srwgt\\1", colnames(iccs_2022))
colnames(iccs_2022_teacher) <- gsub(
  "^trwgt0([1-9])$",
  "trwgt\\1",
  colnames(iccs_2022_teacher))
```

7.2 Przykład 1 – Średnie wyniki uczniów w zakresie wiedzy i rozumienia kwestii obywatelskich w podziale na płeć

```
Analysis_01 <- Rrepest(
  data = iccs_2022,
  svy = "ICCS",
  est = est(c("mean", "std"), target = "pv@civ"),
  by = c("country", "std_gender")
)
print(Analysis_01)
```

7.3 Przykład 2 – Regresja liniowa: wpływ płci ucznia na wyniki w zakresie wiedzy i rozumienia kwestii obywatelskich

```
Analysis_02 <- Rrepest(
  data = iccs_2022,
  svy = "ICCS",
  by = "country",
  est = est("lm", target = "pv@civ", regressor = c("std_gender"))
)
print(Analysis_02, width = 200)
```

Przykładowy kod poprawiający czytelność tabeli wynikowej

```

Table_02 <- Analysis_02 %>%
  transmute(
    country,
    Intercept_Estimate = rowMeans(select(., starts_with("b.reg_pv@civ") &
      ends_with("intercept"))),
    Intercept_SE       = rowMeans(select(., starts_with("se.reg_pv@civ") &
      ends_with("intercept"))),
    Intercept_t        = Intercept_Estimate / Intercept_SE,
    gender_Estimate    = rowMeans(select(., starts_with("b.reg_pv@civ") &
      ends_with("std_gender"))),
    gender_SE          = rowMeans(select(., starts_with("se.reg_pv@civ") &
      ends_with("std_gender"))),
    gender_t           = gender_Estimate / gender_SE,
    R2_Estimate        = rowMeans(select(., starts_with("b.reg_pv@civ") &
      ends_with("rsqr"))),
    R2_SE              = rowMeans(select(., starts_with("se.reg_pv@civ") &
      ends_with("rsqr"))),
    R2_t               = R2_Estimate / R2_SE
  )

make_reg_table <- function(row) {
  data.frame(
    Estimate      = c(row$Intercept_Estimate,
      row$gender_Estimate,
      row$R2_Estimate),
    `Std. Error` = c(row$Intercept_SE,
      row$gender_SE,
      row$R2_SE),
    `t value`     = c(row$Intercept_t,
      row$gender_t,
      row$R2_t),
    row.names = c("(Intercept)", "gender", "R-squared")
  )
}

Table_02 <- setNames(lapply(1:nrow(Table_02),
  function(i) make_reg_table(Table_02[i, ])),
  Table_02$country)

print(Table_02)

```

7.4 Przykład 3 – Partycypacja uczniów w życiu szkoły według dyrektorów szkół

7.4.1 Przykład 3A - Jak często uczniowie są zachęcani do włączania się w planowanie zajęć w klasie? Odsetek uczniów w szkołach, których dyrektorzy odpowiedzieli w określony sposób

```
Analysis_03a <- Rrepest(  
  data = iccs_2022,  
  svy = "ICCS",  
  est = est("freq", target = "ic4g03d"),  
  by = "country"  
)  
print(Analysis_03a, width = 200)
```

7.4.2 Przykład 3B – Jak często uczniowie są zachęcani do włączania się w tworzenie szkolnych zasad i regulaminów? Odsetek uczniów w szkołach, których dyrektorzy odpowiedzieli w określony sposób

```
Analysis_03b <- Rrepest(  
  data = iccs_2022,  
  svy = "ICCS",  
  est = est("freq", target = "ic4g03b"),  
  by = "country"  
)  
print(Analysis_03b, width = 200)
```

7.5 Przykład 4 - Odpowiedzi nauczycieli na pytanie: “Jak ważne dla bycia dobrym obywatelem w dorosłym życiu są następujące zachowania: Uczestniczenie w dyskusjach o polityce”

! Ważne

Aby funkcja `Rrepest()` automatycznie pobrała wagi przypisane do nauczycieli, należy ustawić wartość argumentu `svy = "ICCS_T"`. Jeżeli pozostawimy argument `svy = "ICCS"`, konieczne jest zastosowanie argumentu `custom weights: cm.weights = c("totwgtt", paste0("trwgt", 1:75))`.

```

Analysis_04 <- Rrepest(
  data = iccs_2022_teacher,
  svy   = "ICCS_T",
  est   = est("freq", target = "it4g17e"),
  by    = "country"
)
print(Analysis_04, width = 300)

```

8 Analiza danych TALIS 2018

W przypadku badania TALIS możemy prowadzić analizy na dwóch niezależnych poziomach:

- **TALISTCH** – nauczyciele (domyślne wagi: **TCHWGT** jako waga główna oraz **100** wag replikacyjnych **TRWGT1,..., TRWGT100**).
- **TALISSCH** – dyrektorzy/szkoły (domyślne wagi: **SCHWGT** jako waga główna oraz **100** wag replikacyjnych **SRWGT1,..., SRWGT100**).

Aby funkcja `Rrepest()` wczytała właściwe zmienne wagowe, konieczne jest poprawne ustawienie argumentu `svy`: **svy = "TALISTCH"** dla analiz wykonywanych na zbiorze nauczycielskim, lub **svy = "TALISSCH"** dla analiz wykonywanych na zbiorze szkolnym (dane z kwestionariusza dyrektorów szkół).

8.1 Przygotowanie danych

```

# Krok 1: wskazanie folderu z plikami SPSS
dir_talis_2018 <- "C:/DATA/TALIS 2018/SPSS Data/SPSS_2018_international"

# Krok 2: Wczytanie danych:

# Dane dotyczące nauczycieli - pliki z prefiksem BTG:
talis_2018_tch <- read_sav(file.path(dir_talis_2018, "BTGINTT3.sav"))

# Dane dotyczące dyrektorów szkół - pliki z prefiksem BCG:
talis_2018_sch <- read_sav(file.path(dir_talis_2018, "BCGINTT3.sav"))

# Krok 3: Wybór krajów do analizy (Czechy, Japonia, Kazachstan, Kolumbia)

```

```
# i filtrowanie zbiorów danych:

countries <- c("JPN", "CZE", "COL", "KAZ")

talis_2018_tch <- talis_2018_tch %>% filter(CNTRY %in% countries)
talis_2018_sch <- talis_2018_sch %>% filter(CNTRY %in% countries)

# Krok 4: zmiana wielkości liter w nazwach zmiennych na małe:
names(talis_2018_tch) <- tolower(names(talis_2018_tch))
names(talis_2018_sch) <- tolower(names(talis_2018_sch))
```

8.2 Analizy (TALISTCH - poziom nauczycieli)

8.2.1 Przykład 1 - Tabela rozkładów częstości płci nauczycieli

```
Analysis_01 <- Rrepest(
  data = talis_2018_tch,
  svy = "TALISTCH",
  est = est("freq", target = "tt3g01"),
  by = "cntry"
)
print(Analysis_01)
```

8.2.2 Przykład 2 - Średnia liczba godzin poświęcanych przez nauczycieli tygodniowo na komunikację i współpracę z rodzicami

```
Analysis_02 <- Rrepest(
  data = talis_2018_tch,
  svy = "TALISTCH",
  est = est(c("mean", "std"), target = "tt3g18h"),
  by = "cntry"
)
print(Analysis_02)
```

8.2.3 Przykład 3 - Średnia liczba godzin poświęcanych przez nauczycieli tygodniowo na aktywności związane z rozwojem zawodowym

```
Analysis_03 <- Rrepest(  
  data = talis_2018_tch,  
  svy = "TALISTCH",  
  est = est(c("mean","std"), target = "tt3g18g"),  
  by = "cntry"  
)  
print(Analysis_03)
```

8.2.4 Przykład 4 - Regresja liniowa: wpływ możliwości aktywnego uczestnictwa w decyzjach dotyczących szkoły na ogólny poziom satysfakcji nauczycieli z wykonywanej pracy

```
Analysis_04 <- Rrepest(  
  data = talis_2018_tch,  
  svy = "TALISTCH",  
  by = "cntry",  
  est = est("lm", target = "t3jobsa", regressor = c("tt3g48a"))  
)  
print(Analysis_04, width = 200)
```

Przykładowy kod poprawiający czytelność tabeli wynikowej

```
Table_04 <- Analysis_04 %>%  
  transmute(  
    Country = cntry,  
    Intercept_Estimate = rowMeans(select(., starts_with("b.reg_t3jobsa") &  
                                          ends_with("intercept"))),  
    Intercept_SE = rowMeans(select(., starts_with("se.reg_t3jobsa") &  
                                   ends_with("intercept"))),  
    Intercept_t = Intercept_Estimate / Intercept_SE,  
    tt3g48a_Estimate = rowMeans(select(., starts_with("b.reg_t3jobsa") &  
                                          ends_with("tt3g48a"))),  
    tt3g48a_SE = rowMeans(select(., starts_with("se.reg_t3jobsa") &  
                                   ends_with("tt3g48a"))),  
    tt3g48a_t = tt3g48a_Estimate / tt3g48a_SE,  
    R2_Estimate = rowMeans(select(., starts_with("b.reg_t3jobsa") &
```

```

        ends_with("rsqr"))),
  R2_SE      = rowMeans(select(., starts_with("se.reg_t3jobsa") &
    ends_with("rsqr"))),
  R2_t       = R2_Estimate / R2_SE
)

make_reg_table <- function(row) {
  data.frame(
    Estimate      = c(row$Intercept_Estimate,
      row$tt3g48a_Estimate,
      row$R2_Estimate),
    `Std. Error` = c(row$Intercept_SE,
      row$tt3g48a_SE,
      row$R2_SE),
    `t value`     = c(row$Intercept_t,
      row$tt3g48a_t,
      row$R2_t),
    row.names     = c("(Intercept)", "tt3g48a", "R-squared")
  )
}

Final_04 <- setNames(lapply(1:nrow(Table_04),
  function(i) make_reg_table(Table_04[i, ])),
  Table_04$Country)

print(Final_04)

```

8.3 Analizy (TALISSCH - poziom szkół)

8.3.1 Przykład 5 - Średni staż pracy na stanowisku dyrektora szkoły w obecnym miejscu pracy (w latach)

```

Analysis_05 <- Rrepest(
  data = talis_2018_sch,
  svy   = "TALISSCH",
  est   = est(c("mean", "std"), target = "tc3g04a"),
  by    = "cntry"
)
print(Analysis_05)

```

8.3.2 Przykład 6 - Odsetek dyrektorów szkół, którzy zadeklarowali, że współpracują z nauczycielami przy rozwiązywaniu problemów z dyscypliną w klasie

```
Analysis_06 <- Rrepest(  
  data = talis_2018_sch,  
  svy = "TALISSCH",  
  est = est("freq", target = "tc3g22a"),  
  by = "cntry"  
)  
print(Analysis_06, width = 200)
```

9 Podsumowanie

Pakiet **Rrepest** może być traktowany jako dogodna alternatywa dla programu **IEA IDB Analyzer** w zakresie wykonywania analiz danych z międzynarodowych badań edukacyjnych, szczególnie dla osób pracujących głównie w środowisku R. Rrepest umożliwia automatyzację wielu powtarzalnych procedur, zapewniając obsługę wielu badań edukacyjnych oraz zgodność przeprowadzonych analiz z metodologią badań OECD i IEA. Jednocześnie należy zaznaczyć, że pakiet ten nie obejmuje pełnego zakresu analiz dostępnych np. w **IEA IDB Analyzer** lub w **pakiecie intsvy**.

Zachęcamy do wykorzystywania pakietu we własnych projektach badawczych, testowania jego funkcjonalności w analizie danych z międzynarodowych badań edukacyjnych oraz do zgłaszania uwag i propozycji usprawnień bezpośrednio do autorów pakietu poprzez **repozytorium GitLab**.

10 Bibliografia

- Avvisati, F., & Keslair, F. (2014). *REPEST: Stata module to run estimations with weighted replicate samples and plausible values* (Statistical Software Components S457918). Boston College Department of Economics. (Wersja poprawiona: 11 grudnia 2024 r.).
- Ilizaliturri, R., Avvisati, F., & Keslair, F. (2025). *Rrepest: An analyzer of international large-scale assessments in education* (Version 1.5.4) [R package]. CRAN. <https://CRAN.R-project.org/package=Rrepest>